

2026 《人工智能导论》大作业

(可参考修订)

任务名称：可解释的谣言检测系统

完成组号：第 1 组

小组人员：黄俊艺，王博宇，江世鸿，马轻轩

完成时间：2026 年 6 月

摘要

本项目实现英文推文谣言检测系统。系统基于 train.csv 按 7 个事件训练 Twitter-RoBERTa，并融合 TF-IDF Logistic Regression；预测后检索相似案例，由受约束 LLM 整理中文依据。CLI 与 WebUI 支持训练、预测和批量评测。

关键词：谣言检测；Twitter-RoBERTa；TF-IDF；可解释人工智能；WebUI

1、任务理解与系统设计

针对推文短、噪声多及事件分布不均的问题，系统将分类、检索、解释分离：分类器输出标签与概率，相似案例提供可追溯参考，LLM 仅整理依据，不参与分类。

模块	实现方式	作用
文本清洗	HTML 还原、URL/图片/用户归一、emoji 语义化、hashtag 拆词	降低噪声
分类模型	7 个事件独立的 cardiffnlp/twitter-roberta-base 二分类器	减少跨事件混淆
概率融合	RoBERTa 概率 + TF-IDF Logistic Regression 概率	提升小样本稳健性
解释生成	TF-IDF 余弦检索 + Top-K 相似案例 + 受约束 LLM（轻量级 RAG）	生成可追溯中文依据



图 1 系统整体流程示意图

2、数据集与训练过程

数据字段为 id、text、label、event。train.csv 含 2840 条，标签 0/1 为 1600/1240；val.csv 含 401 条，标签 0/1 为 226/175。字段均完整；训练集有 7 条重复文本，验证集无重复。

数据集	非谣言(0)	谣言(1)	总数	事件数
train.csv	1600	1240	2840	7
val.csv	226	175	401	7



图 2 数据集标签与事件分布统计

训练采用 max_length=128、batch size=8、epochs=8、learning rate=2e-5，并使用类别权重、label smoothing、dropout、梯度裁剪与混合精度。事件内数据按 90%/10% 划分，官方 val.csv 用于阈值、融合权重搜索和最终评测。

3、核心代码分析

核心模块职责明确：src/pipeline.py 编排分类、检索和解释；src/models/transformer.py 加载分事件模型、阈值并输出概率；src/training/trainer.py 完成训练、验证和 checkpoint 保存。

代码位置	主要作用	分析
src/data/preprocess.py	文本归一化	统一处理 URL、@USER、emoji、hashtag 等推文噪声
src/training/trainer.py	模型训练	按事件训练，使用类别权重、label smoothing 和阈值搜索
src/models/transformer.py	模型推理	加载事件模型，融合 RoBERTa 与 TF-IDF 概率
src/pipeline.py	流程编排	连接分类、检索和解释模块，保证接口清晰
src/webui/*	可视化界面	支持单条检测、批量评测、指标展示和配置检查

4、检测结果分析

(1) 批量检测结果说明

批量评测处理 400 条样本，分类耗时 1869.2 ms；Accuracy 90.00%、Precision 89.88%、Recall 86.78%、F1 88.30%，混淆矩阵为 TN=209、FP=17、FN=23、TP=151。

Accuracy	Precision	Recall	F1	TN	FP	FN	TP
90.00%	89.88%	86.78%	88.30%	209	17	23	151



图 3 WebUI 批量评测、混淆矩阵与标签分布截图

结果分析：Accuracy 与 F1 表明模型具有较好的综合判别能力；FN=23 高于 FP=17，说明模型对“谣言”预测相对谨慎，漏判多于误报。

(2) 单条检测样例说明

单条检测在分类结果之外，新增两类概率、关键词证据、Top-K 相似训练样本和中文解释，便于追溯模型判断依据。

本次单条检测使用 val.csv 中的样例：“So, to sum up: 1) Darren Wilson KNEW NOTHING of the robbery, 2) shot #MikeBrown over jaywalking, and 3) was allowed to escape #Ferguson.”

该样例 ID 为 500364250461003777，属于事件 1（Ferguson 与 Michael Brown），真实标签 label=1（谣言）。



图 4 单条推文检测结果与分类置信度截图

图 4 中系统预测为谣言，谣言概率 94.75%、非谣言概率 5.25%，与真实标签一致。置信度仅表示模型的相对判断强度，不代表外部事实核查结论。

5、判断依据分析

解释模块采用 TF-IDF 检索增强的轻量级 RAG 技术，将训练集相似案例作为上下文，再由 LLM 生成受约束中文解释。流程如下：

- (1) 索引构建：读取训练集，用 TF-IDF 将推文转为稀疏向量，并按余弦距离建立最近邻索引；输入新推文后检索 Top-K 相似样本。
- (2) 结果组织：每条检索结果包含训练推文文本、标签、事件和相似度。
- (3) 提示词增强：将相似案例格式化后写入 LLM 提示词，作为模式参考而非外部事实证据。
- (4) 解释生成：LLM 综合输入文本、分类器预测、关键词证据和相似案例生成中文解释，不修改分类标签。

解释来源	具体内容	作用
输入文本	关键词、URL、话题标签、转发和语义表达	说明模型关注的可观察线索
模型输出	预测标签、0/1 概率、事件编号	给出检测结论和置信程度
相似案例	训练集中 Top-K 相似推文及标签	辅助比较同类表达模式
LLM 整理	按约束提示词生成中文依据	提高可读性，但不替代事实核查

💡 解释依据

模型判断解释

模型预测结果：该推文被判定为谣言，置信度高达94.75%。

判断依据分析：

1. 输入文本特征：

推文包含多个高权重敏感词汇，如"NOTHING"（一无所知）、"jaywalking"（乱穿马路）、"allowed to escape"（被允许逃跑）等。这些表述采用绝对化、煽动性的措辞，与典型谣言的修辞模式相符。

1. 关键证据权重：

模型对"jaywalking"（0.688）和"Ferguson"（0.625）赋予最高权重，表明这些词汇在训练数据中与谣言标签有较强关联。

1. 相似案例参考：

模型找到了多个内容高度相似的案例，这些案例同样被标记为谣言。它们涉及相同的当事人（Darren Wilson、Mike Brown）和相同事件（Ferguson），且传播了类似的未经证实的说法。需要强调的是，这些相似案例仅作为模型判断的模式参考，不代表外部事实核查。

综合以上因素，模型基于文本特征匹配和案例模式识别，给出了高置信度的谣言判定。

关键证据词（8）

jaywalking, +0.69

Ferguson." +0.63

robbery, +0.50

NOTHING +0.44

allowed +0.44

Darren +0.38

Wilson +0.38

escape +0.38

图 5 模型判断依据与关键证据词截图

相似案例

来自训练集的 Top-K 相似样本，仅作为参考。

谣言

1

相似度 15.7%

So since we now know the officer knew nothing abt a robbery, we must ask why those tapes were released? Ferguson. But we know why.

谣言

1

相似度 15.7%

UPDATE - Shooter Darren Wilson didn't know Mike Brown was a robbery suspect: Ferguson HTTPURL HTTPURL

谣言

1

相似度 15.3%

This Ferguson PD chief press conference is AMAZING... he just ADMITTED Darren Wilson stopped him bc of the jaywalking.

图 6 训练集 Top-K 相似案例截图

6、部署与运行说明

步骤	命令或说明
安装依赖	<code>pip install -r requirements.txt</code> ; PyTorch 按本机 CUDA/CPU 环境单独安装
训练模型	<code>python -m src.cli.train --config configs/default.yaml</code>
验证评测	<code>python -m src.cli.evaluate --config configs/default.yaml</code>
单条预测	<code>python -m src.cli.predict --config configs/default.yaml --text "input tweet here" --event 1 --no-explain</code>
启动 WebUI	<code>python -m src.webui.main</code>

谣言检测

研判 - Insight

服务状态

单条检测

批量评测

大模型配置

使用提示

先加载模型，再用单条检测验证效果。
需要整体指标时，导入 CSV 进行批量评测。

服务状态

查看后端连接、分类模型与解释配置的实时就绪情况。

服务正常

SERVICE MONITOR

服务运行状态

集中查看后端连接、分类模型与解释配置的实时状态。

100%

就绪度

后端连接

已连接

分类模型接入

已加载

解释模型接入

已配置

解释模型接入

模型

minimax

访问密钥

已保存

服务地址

https://models.sjtu.edu.cn/api/v1

生成随机度

0.2

图 7 WebUI 服务、分类模型与解释模型运行状态截图

大模型配置

设置解释模型的服务地址、访问密钥和模型种类，OpenAI 兼容接口。

● 服务正常

服务地址 (Base URL)

https://models.sjtu.edu.cn/api/v1

访问密钥 (API Key)

留空则不修改已保存的密钥

解释模型

minimax

获取列表

生成随机度 (Temperature)

0.2

稳定灵活

测试连接

保存配置

接入说明

解释服务只在“检测并解释”时使用，不会影响分类结果，也不会参与批量评测。
1. 填写服务地址和访问密钥
2. 获取列表并选择解释模型
3. 保存后返回单条检测页面

参数说明

生成随机度
数值越低，解释越稳定；数值越高，表达会更灵活。

图 8 大语言模型服务地址、模型与生成参数配置截图

代码仓库: https://github.com/accelerator-s/ai_rumor_detection

7、工作总结

(1) 收获、心得:

项目贯通了数据清洗、模型训练、指标评估、部署和可解释性设计，使我们理解了可运行系统不仅要关注准确率，还要保证流程可复现、结果可追溯、解释有边界。

(2) 遇到问题及解决思路:

遇到问题 1:

训练集中出现大量重复或者冲突样本，极大影响模型训练

解决方案 1:

在清洗数据前对所有样本进行去重:

- 1) 对完全相同的样本，仅保留一条;
- 2) 对原始文本完全相同但标签冲突的训练样本，删除全部冲突

遇到问题 2:

数据中出现大量 URL 以及 emoji 表情，可能会影响模型最终判断

解决方案 2:

将图片 URL 归一为 IMAGEURL，其余归一为 HTTPURL。同时，将 emoji 转为英文语义词并将其中的下划线转为空格

遇到问题 3:

训练集中含有大量社交媒体特征词汇，在训练过程中模型会出现误解

解决方案 3:

将@mention、#hashtag 等词汇进行归一化清洗

遇到问题 4:

一些事件训练集数据谣言非谣言比例不均匀，训练出来的分界线低于 50%

解决方案 4:

调整判定的阈值，让模型在谣言率在 30-40 左右就做出判断

遇到问题 5:

不同事件标签相互影响，干扰

解决方案 5:

先考虑添加事件标签的权重的影响，后来发现直接对七个事件分开训练效果更好

遇到问题 6:

由于样本数据太少，导致不少测试样本相似度在 60%左右，模型无法区分

解决方案 6:

未解决，期待后续课程能进一步进行完善

8、课程建议

- 1. 提供更加充实且不矛盾的数据集
- 2. 提供必要的数据集说明
- 3. 提供更加明确的小组评分标准
- 4. 可增设拓展任务，拉开区分度

9、小组协作与项目完成情况

工作项	已完成内容
模型与评测	分事件 RoBERTa、TF-IDF 融合、阈值搜索、val 指标展示
可解释性	关键词证据、相似案例、受约束中文解释
工程部署	CLI、WebUI、批量 CSV、README 运行命令
质量核验	核验数据字段与标签分布；复查 val 指标、运行命令、checkpoint 与评测 JSON

小组分工：

角色	姓名	主要工作内容	贡献率
组长	黄俊艺	项目整体架构搭建、Git 仓库管理、WebUI 及 Cli 开发、模型训练方向确定、解释模块开发、权重文件托管	30%
组员 1	江世鸿	数据集清洗与文本预处理、模型训练验证	25%
组员 2	马轻轩	基础模型确定、模型调参、模型训练验证	25%
组员 3	王博宇	训练结果复现，全套项目文档撰写	20%

参考资料

[1] 《人工智能导论》大作业要求与课程支持文档。

[2] Cardiff NLP twitter-roberta-base 模型说明。

[3] SJTU API 使用指南：<https://claw.sjtu.edu.cn/guide/sjtu-api/>。