

2026《人工智能导论》大作业

(可参考修订)

任务名称：可解释的谣言检测系统

完成组号：

小组人员：黄俊艺，王博宇，江世鸿，马轻轩

完成时间：2026年6月

摘要

本项目实现了一个可运行、可解释的英文推文谣言检测系统。系统以 train.csv 为唯一训练来源，按 7 个事件分别训练 Twitter-RoBERTa 二分类器，并在验证集上搜索阈值与融合权重；推理阶段结合 TF-IDF Logistic Regression、相似案例检索和受约束中文解释，输出 0/1 标签、置信度、相似样本和判断依据。CLI 与 WebUI 支持训练、预测、批量评测和课堂演示。

关键词：谣言检测；Twitter-RoBERTa；TF-IDF；可解释人工智能；WebUI

1、任务理解与系统设计

课程要求输出二分类结果和文字依据，并兼顾泛化能力与运行时间。系统将任务拆成“检测、检索、解释”三层：分类器负责标签与概率，相似案例提供可追溯参考，大语言模型只组织解释文本，不参与最终标签决策。

模块	实现方式	作用
文本清洗	HTML 还原、URL/用户归一、emoji 语义化、hashtag 拆词	降低噪声
分类模型	7 个事件独立的 cardiffnlp/twitter-roberta-base 二分类器	减少跨事件混淆
概率融合	RoBERTa 概率 + TF-IDF Logistic Regression 概率	提升小样本稳健性
解释生成	关键词、Top-K 相似案例、SJTU API 受约束提示词	输出可信判断依据

系统流程截图式示意图




图1 系统整体流程示意图

2、数据集与训练过程

数据字段为 id、text、label、event。train.csv 共 2840 条，标签 0/1 为 1600/1240；val.csv 共 401 条，标签 0/1 为 226/175。两份文件均无缺失字段，训练集原始 text 重复 7 条，验证集无 text 重复。

数据集	非谣言(0)	谣言(1)	总数	事件数
train.csv	1600	1240	2840	7
val.csv	226	175	401	7

数据集标签与事件分布




图2 数据集标签与事件分布统计

训练配置见 configs/default.yaml：seed=42，max_length=128，batch size=8，epochs=8，learning rate=2e-5，head learning rate=5e-5，weight decay=0.01；训练中使用 class weight、label smoothing、dropout、梯度裁剪、梯度累积和混合精度。

3、核心代码分析

项目采用模块化结构，核心流程由数据读取、清洗、模型训练、预测评估、解释生成和 WebUI 展示组成。src/pipeline.py 统一编排分类器、检索器和解释器；src/models/transformer.py 负责加载分事件模型、读取阈值元数据并输出概率；src/training/trainer.py 负责训练、验证和 checkpoint 保存。

代码位置	主要作用	分析
src/data/preprocess.py	文本归一化	统一处理 URL、@USER、emoji、hashtag 等噪声
src/training/trainer.py	模型训练	按事件训练，使用类别权重、label smoothing 和阈值搜索
src/models/transformer.py	模型推理	加载事件模型，融合 RoBERTa 与 TF-IDF 概率
src/pipeline.py	流程编排	连接分类、检索和解释模块
src/webui/*	可视化界面	支持单条检测、批量评测和配置检查

4、检测结果分析（正确率等）

README 中的 WebUI 评测截图显示，本次批量评测处理 400 条样本，耗时 1869.2 ms；Accuracy 90.00%、Precision 89.88%、Recall 86.78%、F1 88.30%，混淆矩阵为 TN=209、FP=17、FN=23、TP=151。val.csv 文件实际含 401 条，本报告保留该差异，避免误写。

Accuracy	Precision	Recall	F1	TN	FP	FN	TP
90.00%	89.88%	86.78%	88.30%	209	17	23	151





图4 单条推文检测结果与分类置信度截图

结果说明：Precision 接近 90%，说明模型对“谣言”预测较谨慎；Recall 为 86.78%，仍有 23 条谣言漏判，后续可优先分析 FN/FP 集中事件。

5、判断依据的分析（可解释性等）

解释内容由输入文本线索、模型预测标签与概率、训练集相似表达三部分组成。提示词明确限制解释范围：相似案例只作为模式参考，不等同于外部事实证据；LLM 不得声称完成事实核查，也不得修改分类器标签。

解释来源	具体内容	作用
输入文本	关键词、URL、话题标签、转发和语义表达	说明模型关注的可观察线索
模型输出	预测标签、0/1 概率、事件编号	给出检测结论和置信程度
相似案例	训练集中 Top-K 相似推文及标签	辅助比较同类表达模式
LLM 整理	按约束提示词生成中文依据	提高可读性，但不替代事实核查

💡 解释依据

模型判断解释

模型预测结果：该推文被判定为谣言，置信度高达94.75%。

判断依据分析：

- 1. 输入文本特征：推文包含多个高权重敏感词汇，如"NOTHING"（一无所知）、"jaywalking"（乱穿马路）、"allowed to escape"（被允许逃跑）等。这些表述采用绝对化、煽动性的措辞，与典型谣言的修辞模式相符。
- 1. 关键证据权重：模型对"jaywalking"（0.688）和"Ferguson"（0.625）赋予最高权重，表明这些词汇在训练数据中与谣言标签有较强关联。
- 1. 相似案例参考：模型找到了多个内容高度相似的案例，这些案例同样被标记为谣言。它们涉及相同的当事人（Darren Wilson、Mike Brown）和相同事件（Ferguson），且传播了类似的未经证实的说法。需要强调的是，这些相似案例仅作为模型判断的模式参考，不代表外部事实核查。

综合以上因素，模型基于文本特征匹配和案例模式识别，给出了高置信度的谣言判定。

关键证据词（8）




图5 模型判断依据与关键证据词截图

📄 相似案例

来自训练集的 Top-K 相似样本，仅作为参考。

谣言 1	相似度 15.7%
So since we now know the officer knew nothing abt a robbery, we must ask why those tapes were released? Ferguson. But we know why.	
谣言 1	相似度 15.7%
UPDATE - Shooter Darren Wilson didn't know Mike Brown was a robbery suspect: Ferguson HTTPURL HTTPURL	
谣言 1	相似度 15.3%
This Ferguson PD chief press conference is AMAZING... he just ADMITTED Darren Wilson stopped him bc of the jaywalking.	

图6 训练集 Top-K 相似案例截图

6、部署与运行说明

步骤	命令或说明
安装依赖	pip install -r requirements.txt; PyTorch 按本机 CUDA/CPU 环境单独安装
训练模型	python -m src.cli.train --config configs/default.yaml
验证评测	python -m src.cli.evaluate --config configs/default.yaml
单条预测	python -m src.cli.predict --config configs/default.yaml --text "input tweet here" --event 1 --no-explain
启动 WebUI	python -m src.webui.main



图7 WebUI 服务、分类模型与解释模型运行状态截图



图8 大语言模型服务地址、模型与生成参数配置截图

代码仓库: https://github.com/accelerator-s/ai_rumor_detection

7、工作总结

（1）收获、心得：本次大作业将机器学习、深度学习、模型评估和可解释性要求串成完整工程流程。相比只训练分类器，项目更强调数据清洗、阈值选择、错误分析、部署复现和解释边界。

（2）遇到问题及解决思路：推文噪声多、事件分布不均、小样本事件难训练、解释容易越界。解决思路是统一清洗、按事件训练、使用类别权重和阈值搜索，并用受约束提示词限制 LLM。

8、课程建议

建议课程继续保留开放题目形式，同时在支持文档中补充“报告结构清单”和“可解释性示例”。若条件允许，也可以提供统一评测脚本或隐藏测试入口，便于比较准确率、运行时间和解释质量。

9、小组协作与改进方向

现有材料记录的小组成员为：黄俊艺，王博宇，江世鸿，马轻轩。仓库可确认的工作流覆盖数据处理、模型训练、阈值搜索、解释生成、WebUI 展示、批量评测与 README 部署说明；组号、学号、组长和贡献比例未在当前材料中出现，提交前应由组长按真实分工补齐。

工作项	已完成内容
模型与评测	分事件 RoBERTa、TF-IDF 融合、阈值搜索、val 指标展示
可解释性	关键词证据、相似案例、受约束中文解释
工程部署	CLI、WebUI、批量 CSV、README 运行命令
后续优化	分析错误集中事件；补充去重后指标；归档 checkpoint 与评测 JSON

参考资料：[1]《人工智能导论》大作业要求与课程支持文档。[2] Cardiff NLP twitter-roberta-base 模型说明与本项目 README。[3] SJTU API 使用指南：<https://claw.sjtu.edu.cn/guide/sjtu-api/>